CAHIER DES CHARGES

Projet de prédiction des prix immobiliers
par le Machine Learning

Intitulé	House Prices Prediction – Analyse et prédiction des prix immobiliers
Domaine	Data Science • Machine Learning • Analyse de données immobilières
Jeu de données	House Prices – Advanced Regression Techniques (Kaggle)
Technologies	Python • SQL Server • Power BI
Version	1.0 — Document de cadrage

Document de référence pour organiser les travaux, définir les objectifs, préciser les livrables et encadrer la réalisation du projet.

1. Contexte et justification du projet

Le secteur immobilier repose sur plusieurs facteurs qui influencent directement la valeur d'un bien : superficie du terrain, surface habitable, nombre de chambres, qualité de construction, emplacement, année de construction et état général du bâtiment.

L'estimation d'un bien immobilier peut être complexe lorsqu'elle repose uniquement sur une appréciation humaine. La Data Science et le Machine Learning permettent d'analyser les caractéristiques des propriétés et de développer des modèles capables d'estimer leur prix de vente.

Ce projet s'appuie sur le jeu de données House Prices – Advanced Regression Techniques, qui décrit des propriétés résidentielles situées à Ames, dans l'Iowa (États-Unis). Il comporte 79 variables explicatives décrivant différents aspects des logements.

Le projet vise à comprendre les facteurs associés aux prix immobiliers et à construire un modèle prédictif capable d'estimer le prix de vente d'une propriété.

2. Problématique

Comment exploiter les caractéristiques d'un bien immobilier pour développer un modèle de Machine Learning capable de prédire son prix de vente avec une erreur minimale ?

Questions auxquelles le projet devra répondre :

- Quelles caractéristiques influencent le plus le prix d'un bien immobilier ?
- Existe-t-il une relation entre la superficie d'un logement et son prix de vente ?
- Dans quelle mesure la localisation influence-t-elle la valeur immobilière ?
- Quels facteurs contribuent le plus à la détermination du prix ?
- Quel algorithme de Machine Learning fournit les meilleures prédictions ?
- Comment rendre les résultats exploitables pour faciliter la prise de décision ?

3. Objectifs du projet

3.1. Objectif général

Concevoir une solution de Data Science permettant d'analyser les caractéristiques des biens immobiliers et de prédire leurs prix de vente à l'aide de techniques de Machine Learning.

3.2. Objectifs spécifiques

- Collecter et comprendre les données immobilières.
- Réaliser un audit de la qualité des données.
- Identifier et traiter les valeurs manquantes et les éventuelles anomalies.
- Effectuer une analyse exploratoire des données (EDA).
- Identifier les variables les plus importantes pour l'estimation des prix.
- Transformer les données et créer de nouvelles variables pertinentes (Feature Engineering).
- Construire plusieurs modèles de régression et comparer leurs performances.
- Optimiser et sélectionner le modèle le plus performant.
- Enregistrer les données préparées et les résultats dans SQL Server.
- Concevoir un tableau de bord interactif avec Power BI.
- Produire un fichier de prédictions conforme au format de soumission Kaggle.

4. Description du jeu de données

Le projet repose sur les fichiers fournis avec la compétition Kaggle :

Fichier	Description
train.csv	Données d'entraînement contenant les caractéristiques des propriétés et leur prix de vente.
test.csv	Données de test contenant les caractéristiques des propriétés, sans le prix de vente.
data_description.txt	Documentation détaillée des variables du jeu de données.
sample_submission.csv	Exemple de fichier de soumission contenant des prédictions de référence.

4.1. Variable cible

SalePrice : prix de vente du bien immobilier, exprimé en dollars. Cette variable constitue la cible que le modèle devra apprendre à prédire.

4.2. Principales familles de variables explicatives

- Terrain : LotArea, LotFrontage, LotShape.
- Localisation : Neighborhood, MSZoning.
- Bâtiment : BldgType, HouseStyle, YearBuilt.
- Qualité : OverallQual, OverallCond, ExterQual.
- Espaces intérieurs : GrLivArea, Bedroom, Kitchen, FullBath.
- Sous-sol : TotalBsmtSF, BsmtQual, BsmtFinSF1.
- Garage : GarageCars, GarageArea, GarageType.
- Aménagements extérieurs : WoodDeckSF, OpenPorchSF, PoolArea.
- Vente : MoSold, YrSold, SaleType, SaleCondition.

La documentation complète des colonnes devra être consultée pendant la phase de compréhension et de préparation des données.

5. Périmètre fonctionnel du projet

Le projet est organisé autour de six axes complémentaires.

Axe 1 — Collecte et compréhension des données

- Récupération des fichiers depuis Kaggle.
- Chargement des fichiers avec Python et Pandas.
- Identification des dimensions et des types de variables.
- Compréhension de la signification des colonnes.
- Vérification de la cohérence entre les fichiers d'entraînement et de test.

Livrable : notebook d'audit et de compréhension des données.

Axe 2 — Nettoyage et préparation des données

- Identification des valeurs manquantes et analyse des doublons.
- Détection des valeurs aberrantes et vérification des incohérences.
- Traitement des valeurs manquantes selon leur signification.
- Encodage des variables catégorielles.
- Normalisation ou standardisation lorsque nécessaire.
- Création de nouvelles variables pertinentes.
- Préparation des jeux de données pour la modélisation.

Une attention particulière sera accordée aux valeurs manquantes qui peuvent signifier l'absence réelle d'un équipement, par exemple l'absence de garage ou de piscine.

Livrable : jeu de données nettoyé et préparé pour la modélisation.

Axe 3 — Analyse exploratoire des données (EDA)

- Distribution des prix de vente.
- Répartition des propriétés par quartier.
- Relation entre la superficie habitable et le prix.
- Influence de la qualité générale du bâtiment.
- Évolution des prix selon l'année de construction.
- Relation entre le nombre de chambres et le prix.
- Corrélations entre les variables numériques et SalePrice.
- Identification des variables associées au prix.

Livrable : notebook EDA avec visualisations et interprétations.

Axe 4 — Modélisation et prédiction

Les algorithmes envisagés sont :

- Régression linéaire.
- Ridge Regression et Lasso Regression.
- Random Forest Regressor.
- Gradient Boosting Regressor.
- XGBoost Regressor.

Les travaux comprendront la séparation des données d'entraînement et de validation, la construction d'une baseline, l'entraînement des modèles, l'évaluation, la comparaison, l'optimisation des hyperparamètres et la sauvegarde du modèle retenu.

Livrable : modèle prédictif entraîné, évalué et sauvegardé.

Axe 5 — Gestion des données avec SQL Server

SQL Server servira à centraliser les données et à faciliter leur exploitation. Une organisation en trois couches est proposée :

Couche	Rôle
Bronze	Stockage des données brutes issues des fichiers CSV.
Silver	Stockage des données nettoyées et préparées.
Gold	Stockage des données finales destinées à l'analyse et à la visualisation.

Les opérations incluront la création de la base et des schémas, l'importation des CSV, les transformations, la création de vues analytiques et la mise à disposition des données pour Power BI.

Livrable : base de données SQL Server structurée et documentée.

Axe 6 — Visualisation et reporting avec Power BI

Le tableau de bord pourra comporter quatre pages :

Page	Contenu envisagé
1. Vue d'ensemble	Nombre de propriétés, prix moyen et médian, prix minimum et maximum, répartition par quartier et distribution des prix.
2. Caractéristiques immobilières	Prix selon la superficie habitable, la qualité du bâtiment, le nombre de chambres et l'année de construction.
3. Facteurs influençant les prix	Variables importantes, corrélations, comparaison des prix par quartier et influence des équipements.
4. Résultats de modélisation	Comparaison des modèles, métriques d'évaluation, performance du modèle sélectionné et importance des variables.

Livrable : tableau de bord Power BI interactif.

6. Méthodologie de réalisation

Phase	Activités principales	Résultat attendu
1. Compréhension	Étude du besoin et du jeu de données.	Problématique définie.
2. Audit	Exploration et contrôle de la qualité.	Rapport d'audit.
3. Nettoyage	Traitement des valeurs manquantes et anomalies.	Données propres.
4. EDA	Analyses statistiques et graphiques.	Insights métier.
5. Feature Engineering	Transformation et création de variables.	Données optimisées.
6. Modélisation	Entraînement des algorithmes.	Modèles prédictifs.
7. Évaluation	Comparaison et optimisation.	Modèle sélectionné.
8. SQL Server	Stockage et structuration.	Base de données.
9. Power BI	Analyse et visualisation.	Dashboard.
10. Documentation	Rapport et présentation.	Projet documenté.

7. Technologies et outils

Technologie / outil	Utilisation
Python	Développement du projet Data Science.
Pandas / NumPy	Manipulation des données et calculs numériques.
Matplotlib / Seaborn	Visualisation et analyse graphique.
Scikit-learn	Prétraitement et Machine Learning.
XGBoost	Modélisation par Gradient Boosting.
Jupyter Notebook / Google Colab	Environnement de développement.
SQL Server / SQL	Stockage, requêtes et transformations.
Power BI	Visualisation et reporting.
Git / GitHub	Gestion des versions et partage du projet.

8. Indicateurs de performance du modèle

- MAE (Mean Absolute Error) : erreur absolue moyenne entre les prix réels et prédits.
- MSE (Mean Squared Error) : moyenne des erreurs au carré.
- RMSE (Root Mean Squared Error) : racine carrée de l'erreur quadratique moyenne.
- R^2 : proportion de variance de la variable cible expliquée par le modèle.
- RMSLE (Root Mean Squared Logarithmic Error) : métrique officielle de la compétition, calculée à partir des logarithmes des prix réels et prédits.

Le modèle final devra notamment chercher à minimiser le RMSLE. Les résultats des différentes métriques seront calculés sur un jeu de validation distinct des données utilisées pour l'entraînement.

9. Livrables attendus

- Cahier des charges du projet.
- Documentation et dictionnaire des données.
- Notebook d'audit et de compréhension des données.
- Notebook de nettoyage et de préparation.
- Notebook d'analyse exploratoire.
- Notebook de Feature Engineering.
- Notebook de modélisation et d'évaluation.
- Modèle Machine Learning sauvegardé.
- Base de données SQL Server.
- Scripts SQL de création et de transformation.
- Tableau de bord Power BI.
- Fichier de prédictions au format CSV.
- Rapport final présentant la démarche et les résultats.
- Dépôt GitHub contenant le code source et la documentation.

10. Contraintes et risques du projet

- Présence éventuelle de valeurs manquantes.
- Présence de variables catégorielles et numériques.
- Distribution des prix potentiellement asymétrique.
- Présence possible de valeurs aberrantes.
- Risque de surapprentissage (Overfitting).
- Risque de fuite de données (Data Leakage).
- Nécessité de séparer correctement entraînement, validation et test.
- Différences possibles de distribution entre train.csv et test.csv.

Les transformations doivent être ajustées sur les données d'entraînement, puis appliquées aux données de validation et de test. Aucune information de la variable cible ne doit être utilisée depuis le jeu de test.

11. Résultats attendus

- Comprendre les principaux facteurs associés aux prix immobiliers.
- Identifier les caractéristiques importantes pour l'estimation d'un bien.
- Développer et comparer plusieurs modèles de régression.
- Sélectionner un modèle capable de produire des estimations fiables.
- Centraliser les données dans SQL Server.
- Présenter les résultats à travers un tableau de bord Power BI.
- Générer des estimations de prix pour les propriétés de test.csv.

12. Architecture technique recommandée

Couche	Technologie	Fonction
Collecte	Kaggle / CSV	Récupération des données.
Traitement	Python / Pandas	Audit, nettoyage et préparation.
Analyse	Python	Analyse exploratoire.
Machine Learning	Scikit-learn / XGBoost	Entraînement et prédiction.
Stockage	SQL Server	Centralisation des données.
Visualisation	Power BI	Reporting et analyse.
Versionnement	GitHub	Gestion du code source.

13. Organisation recommandée du dépôt GitHub

house_prices_prediction/
├── data/
│ ├── bronze/ (train.csv, test.csv)
│ ├── silver/
│ └── gold/
├── notebooks/
│ ├── 01_data_understanding.ipynb
│ ├── 02_data_cleaning.ipynb
│ ├── 03_exploratory_data_analysis.ipynb
│ ├── 04_feature_engineering.ipynb
│ ├── 05_model_training.ipynb
│ └── 06_model_evaluation.ipynb
├── sql/ (scripts de création, chargement et vues)
├── models/ (best_model.pkl)
├── powerbi/ (house_prices_dashboard.pbix)
├── predictions/ (submission.csv)
├── reports/ (project_report.pdf)
├── requirements.txt
├── README.md
└── .gitignore

14. Conclusion

Ce projet permettra de mettre en pratique les différentes étapes d'un projet Data Science, depuis la compréhension des données jusqu'à la valorisation des résultats.

Il constituera également une occasion de développer des compétences complémentaires en Machine Learning, en gestion de bases de données et en Business Intelligence.

L'objectif final est de concevoir une solution cohérente, documentée et reproductible, capable de transformer des données immobilières en informations utiles à la compréhension et à l'estimation des prix des biens immobiliers.

Point de vigilance méthodologique

Le fichier test.csv ne contient pas la variable SalePrice. Il ne doit donc pas servir à calculer directement les performances du modèle. L'évaluation doit être réalisée sur un jeu de validation extrait de train.csv. Après sélection du modèle, celui-ci pourra être réentraîné sur l'ensemble des données d'entraînement et utilisé pour produire les prédictions destinées à la soumission Kaggle.

Référence du jeu de données : Kaggle — House Prices: Advanced Regression Techniques. La compétition demande de prédire SalePrice et évalue les soumissions avec le RMSLE.