DICTIONNAIRE DE DONNÉES

Projet House Prices — Advanced Regression Techniques

1. Présentation du jeu de données

Ce document décrit les variables du jeu de données *House Prices — Advanced Regression Techniques*, utilisé pour construire un modèle de prédiction du prix de vente des logements situés à Ames, dans l'Iowa (États-Unis). Le jeu d'entraînement contient la variable cible **SalePrice** ; le jeu de test contient les variables explicatives mais ne comporte pas cette cible.

Structure attendue : 1 identifiant (*Id*), 79 variables explicatives et 1 variable cible (*SalePrice*) dans le fichier d'entraînement. Le fichier de test ne contient pas *SalePrice*.

2. Dictionnaire des variables

Identification	**Id**	Identifiant unique de l'enregistrement immobilier.
Localisation et terrain	**MSSubClass**	Classe du bâtiment ou type de logement concerné par la vente.
Localisation et terrain	**MSZoning**	Classification générale du zonage de la propriété.
Localisation et terrain	**LotFrontage**	Longueur de façade du terrain donnant sur une rue (pieds linéaires).
Localisation et terrain	**LotArea**	Superficie totale du terrain (pieds carrés).
Localisation et terrain	**Street**	Type de voie d'accès à la propriété.
Localisation et terrain	**Alley**	Type d'accès par ruelle, lorsqu'il existe.
Localisation et terrain	**LotShape**	Forme générale du terrain.
Localisation et terrain	**LandContour**	Configuration et niveau du terrain.
Localisation et terrain	**Utilities**	Type de services publics disponibles.
Localisation et terrain	**LotConfig**	Configuration du terrain par rapport aux voies et aux parcelles voisines.
Localisation et terrain	**LandSlope**	Degré d'inclinaison du terrain.
Localisation et terrain	**Neighborhood**	Quartier où se situe la propriété dans la ville d'Ames.

Localisation et terrain	**Condition1**	Proximité d'une route principale, d'une voie ferrée ou d'un autre élément.
Localisation et terrain	**Condition2**	Seconde condition de proximité, si elle existe.
Bâtiment et architecture	**BldgType**	Type de bâtiment résidentiel.
Bâtiment et architecture	**HouseStyle**	Style architectural ou configuration des étages.
Bâtiment et architecture	**OverallQual**	Évaluation globale de la qualité des matériaux et des finitions.
Bâtiment et architecture	**OverallCond**	Évaluation globale de l'état général du bâtiment.
Bâtiment et architecture	**YearBuilt**	Année de construction initiale.
Bâtiment et architecture	**YearRemodAdd**	Année de rénovation ou de modification importante.
Toiture et extérieur	**RoofStyle**	Forme ou style de la toiture.
Toiture et extérieur	**RoofMatl**	Matériau utilisé pour la toiture.
Toiture et extérieur	**Exterior1st**	Matériau principal du revêtement extérieur.
Toiture et extérieur	**Exterior2nd**	Matériau secondaire du revêtement extérieur, le cas échéant.
Toiture et extérieur	**MasVnrType**	Type de parement ou de placage en maçonnerie.
Toiture et extérieur	**MasVnrArea**	Superficie du parement en maçonnerie (pieds carrés).
Toiture et extérieur	**ExterQual**	Qualité du matériau extérieur.
Toiture et extérieur	**ExterCond**	État actuel du matériau extérieur.
Structure et sous-sol	**Foundation**	Type de fondation du bâtiment.
Structure et sous-sol	**BsmtQual**	Hauteur ou qualité du sous-sol.
Structure et sous-sol	**BsmtCond**	État général du sous-sol.
Structure et sous-sol	**BsmtExposure**	Niveau d'exposition des murs du sous-sol, notamment à la lumière ou à l'extérieur.
Structure et sous-sol	**BsmtFinType1**	Qualité ou niveau de finition de la première zone aménagée du sous-sol.
Structure et sous-sol	**BsmtFinSF1**	Superficie aménagée de type 1 au sous-sol (pieds carrés).
Structure et sous-sol	**BsmtFinType2**	Qualité ou niveau de finition de la deuxième zone aménagée du sous-sol.

Structure et sous-sol	**BsmtFinSF2**	Superficie aménagée de type 2 au sous-sol (pieds carrés).
Structure et sous-sol	**BsmtUnfSF**	Superficie non aménagée du sous-sol (pieds carrés).
Structure et sous-sol	**TotalBsmtSF**	Superficie totale du sous-sol (pieds carrés).
Équipements et installations	**Heating**	Type de système de chauffage.
Équipements et installations	**HeatingQC**	Qualité et état du système de chauffage.
Équipements et installations	**CentralAir**	Présence ou absence d'un système de climatisation central.
Équipements et installations	**Electrical**	Type d'installation électrique.
Surfaces et pièces	**1stFlrSF**	Superficie du premier étage (pieds carrés).
Surfaces et pièces	**2ndFlrSF**	Superficie du deuxième étage (pieds carrés).
Surfaces et pièces	**LowQualFinSF**	Superficie habitable finie de faible qualité, tous étages confondus (pieds carrés).
Surfaces et pièces	**GrLivArea**	Superficie habitable hors sol (pieds carrés).
Surfaces et pièces	**BsmtFullBath**	Nombre de salles de bains complètes au sous-sol.
Surfaces et pièces	**BsmtHalfBath**	Nombre de salles d'eau ou demi-salles de bains au sous-sol.
Surfaces et pièces	**FullBath**	Nombre de salles de bains complètes hors sous-sol.
Surfaces et pièces	**HalfBath**	Nombre de demi-salles de bains hors sous-sol.
Surfaces et pièces	**BedroomAbvGr**	Nombre de chambres situées au-dessus du niveau du sous-sol.
Surfaces et pièces	**KitchenAbvGr**	Nombre de cuisines au-dessus du niveau du sous-sol.
Surfaces et pièces	**KitchenQual**	Qualité de la cuisine.
Surfaces et pièces	**TotRmsAbvGrd**	Nombre total de pièces au-dessus du niveau du sous-sol, hors salles de bains.
Surfaces et pièces	**Functional**	Évaluation du niveau de fonctionnalité du logement.
Équipements et annexes	**Fireplaces**	Nombre de cheminées.
Équipements et annexes	**FireplaceQu**	Qualité des cheminées.
Garage et stationnement	**GarageType**	Emplacement ou type de garage.

Garage et stationnement	**GarageYrBlt**	Année de construction du garage.
Garage et stationnement	**GarageFinish**	Niveau de finition intérieure du garage.
Garage et stationnement	**GarageCars**	Capacité du garage, exprimée en nombre de voitures.
Garage et stationnement	**GarageArea**	Superficie du garage (pieds carrés).
Garage et stationnement	**GarageQual**	Qualité du garage.
Garage et stationnement	**GarageCond**	État général du garage.
Garage et stationnement	**PavedDrive**	État ou type de revêtement de l'accès automobile.
Espaces extérieurs	**WoodDeckSF**	Superficie de la terrasse en bois (pieds carrés).
Espaces extérieurs	**OpenPorchSF**	Superficie du porche ouvert (pieds carrés).
Espaces extérieurs	**EnclosedPorch**	Superficie du porche fermé (pieds carrés).
Espaces extérieurs	**3SsnPorch**	Superficie du porche utilisable sur trois saisons (pieds carrés).
Espaces extérieurs	**ScreenPorch**	Superficie du porche avec moustiquaire (pieds carrés).
Espaces extérieurs	**PoolArea**	Superficie de la piscine (pieds carrés).
Espaces extérieurs	**PoolQC**	Qualité de la piscine.
Espaces extérieurs	**Fence**	Qualité ou niveau de la clôture.
Éléments divers	**MiscFeature**	Caractéristique particulière non couverte par les autres variables.
Éléments divers	**MiscVal**	Valeur monétaire associée à une caractéristique diverse.
Informations sur la vente	**MoSold**	Mois de la vente.
Informations sur la vente	**YrSold**	Année de la vente.
Informations sur la vente	**SaleType**	Type de transaction ou de vente.
Informations sur la vente	**SaleCondition**	Condition ou contexte de la vente.
Variable cible	**SalePrice**	Prix final de vente du bien immobilier, en dollars. Variable cible à prédire.

3. Points d'attention pour la préparation des données

• **Valeurs manquantes :** elles ne signifient pas systématiquement que l'information est inconnue. Pour certaines variables, elles peuvent indiquer l'absence de l'équipement concerné (par exemple piscine, garage, clôture ou accès par ruelle). Il faut vérifier la signification de chaque variable avant de choisir une méthode d'imputation.

• **Variables catégorielles codées :** certaines variables stockées sous forme numérique, notamment *MSSubClass*, *MoSold* ou *YrSold*, représentent des classes ou des périodes. Leur type informatique ne suffit pas à déterminer leur nature statistique.

• **Unités :** les superficies sont généralement exprimées en pieds carrés (square feet), les longueurs en pieds linéaires, et le prix de vente en dollars américains.

• **Variable cible :** *SalePrice* est la valeur à prédire. Elle est disponible dans *train.csv* et absente de *test.csv*.

4. Source et périmètre

Les descriptions sont des traductions et reformulations synthétiques de la documentation officielle fournie pour la compétition Kaggle. Ce dictionnaire présente les définitions des variables ; il ne remplace pas le fichier complet *data_description.txt*, qui précise également les modalités et codes possibles de plusieurs variables.

Source : Kaggle, *House Prices — Advanced Regression Techniques*, documentation du jeu de données.